

Reconocimiento de deletreo manual en lenguaje de señas

Google · ASL Fingerspelling Recognition (Kaggle, 2023)

María José Girón Isidro · Leonardo Dufrey Mejía Mejía · Cindy Mishelle Gualim Pérez
Daniela Ramírez de León · José Donado



01

El caso y el problema

Qué es el deletreo manual, por qué es difícil de reconocer y qué nos preguntamos.



¿Qué es el deletreo manual?

- Se deletrea letra por letra lo que no tiene seña propia: nombres, direcciones, siglas y términos técnicos.
- Lo usan a diario la comunidad sorda, intérpretes y estudiantes de ASL.
- Se hace con una mano, a la altura del hombro y con la palma hacia quien recibe el mensaje.

TRES USOS PRINCIPALES

Nombres propios (personas, países, ciudades)

Términos técnicos o palabras sin seña establecida

Siglas y acrónimos

12 – 35 %

del discurso en ASL es deletreo manual

5 – 6

letras por segundo: es rapidísimo

Por qué es un reto distinto

1

Movimiento, no forma

El significado está en cómo se mueve la mano en el tiempo, no en una foto suelta.

2

Coarticulación

La mano ya se está acomodando para la letra siguiente mientras hace la actual.

3

Letras parecidas

M, N y T se distinguen por detalles mínimos de los dedos.

4

Variabilidad

Cambia con la persona, la iluminación, el encuadre y la oclusión.

Problema a resolver

¿Cuáles son las características, la calidad y la variabilidad de las secuencias de landmarks de manos, rostro y pose, y qué debe corregirse antes de usarlas para transcribir frases deletreadas?

PREGUNTAS ESPECÍFICAS

- ¿Qué variables y observaciones componen el conjunto, y de qué tipo son?
- ¿Cómo se distribuyen la duración de las secuencias y la longitud de las frases?
- ¿Qué proporción de valores faltantes hay por región del cuerpo?
- ¿Hay diferencias sistemáticas entre participantes que exijan normalizar?
- ¿Qué observaciones deben excluirse, y bajo qué criterio explícito?

Delimitación: el estudio se queda en el análisis exploratorio. No se entrena ni se evalúa ningún modelo.

OBJETIVOS

Qué nos propusimos

OBJETIVO GENERAL

Caracterizar la estructura, la calidad y la variabilidad del conjunto para justificar con evidencia empírica la limpieza que requiere antes de construir un modelo.

OBJETIVOS ESPECÍFICOS

- 1 Inventariar variables, observaciones y tipos de dato.
- 2 Cuantificar los valores faltantes por región anatómica.
- 3 Describir la duración de las secuencias y la longitud de las frases.
- 4 Evaluar diferencias entre participantes y correlaciones entre variables.
- 5 Elaborar gráficos exploratorios que evidencien distribuciones y valores atípicos.

02

Los datos

Qué entrega la competencia, cómo está estructurado y cómo lo dejamos listo.



Landmarks, no video

- MediaPipe convierte cada cuadro de video en puntos con coordenadas x, y, z.
- 468 puntos de rostro, 33 de pose y 21 por cada mano.
- Se entregan coordenadas y no video por privacidad, por tamaño (158 GB) y para no aprender el fondo ni la iluminación.




Figura 1. Landmarks de un cuadro real: rostro, pose y mano derecha.

Estructura del conjunto

67,208

secuencias en train.csv

5

columnas en train.csv

94

participantes distintos

1,630

columnas por cuadro

- train.csv trae una fila por secuencia; los landmarks vienen aparte, en archivos parquet.
- Cada parquet trae cerca de 1,000 secuencias, indexadas por sequence_id, que es el índice de la tabla y no una columna.
- La participación es despareja: de 1 a 1,535 secuencias por persona, con mediana de 794.
- Trabajamos con una muestra fija de dos archivos de landmarks, de alrededor de 1.5 GB cada uno.

Variables disponibles

VARIABLE	TIPO	DESCRIPCIÓN
path	texto	Ruta al archivo de landmarks de esa secuencia.
phrase	texto	Frase deletreada: de 1 a 31 caracteres, mediana de 17.
file_id	entero	Identificador del archivo parquet.
sequence_id	entero	Identificador de la secuencia; es el índice del parquet.
participant_id	entero	Identificador de la persona que deletrea: 94 en total.

Los tres enteros son identificadores: no se pueden promediar.

Por eso el análisis se apoya en tres variables derivadas: longitud de frase, longitud de secuencia y porcentaje de cuadros sin mano detectada.

El problema no es suciedad, son detecciones faltantes

54.5 %

de los cuadros sin mano derecha detectada

- El rostro falta en 0.7 % de los cuadros; la mano derecha, en 54.5 %.
- MediaPipe no reporta la mano cuando no la detecta: sale del cuadro, se ocluye o se mueve muy rápido.
- El faltante se concentra justo en la parte del cuerpo que más informa sobre el deletreo.




Figura 2. Proporción de valores faltantes por tipo de landmark.

Qué hicimos con eso

1

Forward-fill

Se arrastra el último valor válido dentro de cada secuencia. No se interpola ni se rellena con ceros: un cero pondría la mano en el origen e inventaría movimiento.

2

Menos columnas

Se eliminaron los 468 puntos de rostro, que son el 86 % de las columnas y aportan poco al deletreo.

3

Secuencias fuera

Se descartan las secuencias con alguna mano detectada en menos del 10 % de sus cuadros: sin mano no hay deletreo que analizar.

1,630 → 226

columnas por cuadro después de la limpieza

10 %

umbral mínimo de cuadros con mano detectada

03

Análisis exploratorio

Univariado, bivariado y multivariado, con los gráficos que lo sostienen.



Longitud de frase: acotada y estable

17.8

caracteres en promedio por frase

- De 1 a 31 caracteres, con media de 17.8 y mediana de 17.
- Distribución casi simétrica, con una moda marcada en 12 caracteres.
- El tope de 31 parece un límite de diseño de las frases, no algo propio del lenguaje.




Figura 3. Distribución de la longitud de frase sobre las 67,208 secuencias.

Longitud de secuencia: variable y sesgada

147

cuadros de mediana por secuencia

- Media de 160.8 cuadros y mediana de 147.
- Cola larga hacia la derecha que llega hasta 751 cuadros, con asimetría de 1.09.
- El porcentaje de cuadros sin mano detectada promedia 44.8 %, con mediana de 42.9 %.




Figura 4. Distribución de la longitud de secuencia, con sesgo a la derecha.

Un alfabeto pequeño y muy desbalanceado

- En las frases aparecen 59 símbolos distintos.
- 61.2 % letras, 24.6 % dígitos, 4.9 % espacios y 9.3 % otros símbolos.
- e, a, o, r, n y t concentran la mayoría; j, q y z casi no tienen muestras.




Figura 5. Frecuencia absoluta de cada carácter en las frases objetivo.

A mayor frase, secuencias más largas

$$r = 0.60$$

correlación de Pearson entre frase y secuencia

- Correlación positiva y moderada entre longitud de frase y longitud de secuencia.
- No es una relación estricta: para la misma frase hay duraciones muy distintas.
- La velocidad de deletreo cambia de una persona a otra.




Figura 6. Longitud de frase contra longitud de secuencia, con línea de tendencia.

Cada quien deletrea a su ritmo

- Las medianas por participante van de 75 a 241 cuadros.
- La mediana global de la muestra es de 147 cuadros.
- Hay estilos de deletreo claramente más rápidos y más lentos.




Figura 7. Longitud de secuencia por participante, contra la mediana global de 147 cuadros.

Correlaciones y valores atípicos

0.60

Longitud de frase y longitud de secuencia

-0.19

Landmarks faltantes y longitud de secuencia

-0.01

Longitud de frase y landmarks faltantes

28 de 998

secuencias atípicas (cerca del 3 %) con el criterio de $1.5 \times \text{IQR}$. Los límites normales son 0 a 359 cuadros y 0 a 37 caracteres: todas las atípicas lo son por largas, ninguna por corta.




Figura 8. Matriz de correlación de las tres variables derivadas.

Cómo se mueve una mano al deletrear

- Trayectoria en dos dimensiones de los landmarks de la mano a lo largo de una secuencia completa.
- Las zonas densas corresponden a pausas y cambios de forma entre letras.
- Refuerza la idea central: el orden temporal importa tanto como la posición.




Figura 9. Trayectoria 2D de los landmarks de la mano en una secuencia de ejemplo.

04

Hallazgos y conclusiones

Qué encontramos y qué implica para las siguientes etapas.



Lo que encontramos

1

Faltan justo las manos

El rostro falta en 0.7 % de los cuadros y la mano derecha en 54.5 %: el problema se concentra en la región más informativa.

2

Desbalance doble

94 participantes con entre 1 y 1,535 secuencias, y 59 caracteres donde unas pocas letras dominan.

3

Entrada variable, salida estable

La secuencia va de decenas a más de 700 cuadros; la frase se queda entre 1 y 31 caracteres.

4

Una sola relación fuerte

$r = 0.60$ entre frase y secuencia. Los demás cruces son débiles o prácticamente nulos.

Próximos pasos para el modelado

- 1 Tratar los faltantes con forward-fill, nunca con ceros ni interpolación.
- 2 Descartar las columnas de rostro: 86 % de las columnas y poco aporte al deletreo.
- 3 Separar entrenamiento y validación por participante, no al azar.
- 4 Aceptar secuencias de longitud variable, con recorte o relleno.
- 5 Reportar el desempeño por carácter y no solo el promedio general.

El entrenamiento y la evaluación de un modelo de transcripción quedan fuera del alcance de esta fase.

Gracias

Preguntas y comentarios

REPOSITORIO DEL PROYECTO

github.com/DufreyM/CC3084-Proyecto2

